

Detecção de Intrusões em Redes CAN de Sistemas Veiculares: Uma Abordagem Baseada em Machine Learning

João Pedro Daltro Marques e José Valentim dos Santos Filho

Resumo—Este trabalho propõe um modelo de detecção de intrusões para redes veiculares baseadas em *Controller Area Network (CAN)*, utilizando técnicas de *machine learning*. Foram utilizados dois conjuntos de dados do mundo real, contendo tipos de ataque como *Denial of Service (DoS)*, *Fuzzy* e *Spoofing*. Após o pré-processamento e a fusão dos dados, um classificador *Perceptron de Múltiplas Camadas (MLP)* foi treinado para identificar mensagens maliciosas. O modelo alcançou uma acurácia de 99,96% e apresentou excelente desempenho em diferentes tipos de ataque. Os resultados demonstram a viabilidade da aplicação de *machine learning* para reforçar a cibersegurança em sistemas automotivos conectados.

Palavras chave—Detecção de intrusões, *Controller Area Network*, *dataset*, pré-processamento, *machine learning*

I. SEGURANÇA VEICULAR E OS DESAFIOS DO PROTOCOLO CAN

A *Internet das Coisas (IoT)* tem transformado diversos setores, incluindo a indústria automotiva. Veículos modernos deixaram de ser apenas meios de transporte e passaram a atuar como *nós inteligentes* conectados à internet, capazes de trocar informações com outros veículos, com a infraestrutura urbana e com servidores em nuvem. Essa integração, chamada de *Internet of Vehicles (IoV)*, visa melhorar a segurança no trânsito, otimizar rotas e permitir atualizações remotas de software, entre outras funcionalidades [1].

No entanto, à medida que os veículos se tornam mais conectados, aumentam também os riscos relacionados à segurança cibernética. Um dos principais componentes da arquitetura veicular é a rede *Controller Area Network (CAN)*, responsável pela comunicação entre os módulos eletrônicos do carro, como freios, motor, painel, câmbio e sensores. O protocolo CAN foi projetado para ser leve, rápido e eficiente, mas sem considerar aspectos de segurança como autenticação, criptografia ou verificação de integridade [2].

Essa ausência de mecanismos de proteção torna a rede CAN vulnerável a uma série de ataques cibernéticos, como a injeção de mensagens falsas, ataques de *Denial of Service (DoS)* e falsificação de sinais (*spoofing*). Esses ataques podem comprometer o funcionamento de sistemas críticos do veículo, colocando em risco a segurança de motoristas e passageiros. Diante desse cenário, surge a necessidade de desenvolver métodos inteligentes para a detecção de intrusões em tempo

real, aproveitando o potencial de técnicas de *machine learning* para identificar padrões anômalos no tráfego da rede CAN [3].

II. ATAQUES EM REDES CAN: UM PANORAMA REALISTA

A ausência de mecanismos de autenticação e criptografia no protocolo CAN permite que qualquer dispositivo legítimo conectado ao barramento tenha capacidade de enviar mensagens, independentemente da sua legitimidade. Essa fragilidade é explorada nos principais datasets utilizados neste trabalho (Car-Hacking Dataset e CIC-IoV2024), nos quais os ataques foram implementados por injeção direta de frames maliciosos via porta OBD-II ou equipamentos conectados ao barramento. Em um contexto real, a superfície de ataque em veículos modernos é ampliada devido à integração de módulos com interfaces externas — como sistemas telemáticos, Bluetooth, Wi-Fi, redes celulares (4G/5G) e portas OBD-II. Os sistemas telemáticos, em particular, funcionam como uma ponte entre a rede veicular interna e o mundo exterior. Se comprometidos por malware, podem atuar como nós maliciosos capazes de enviar frames falsos ao barramento CAN, viabilizando ataques [1].

Entre os ataques mais comuns estão:

- **Denial-of-Service (DoS):** consiste no envio contínuo de mensagens de alta prioridade para sobrecarregar a rede e impedir a comunicação entre os módulos legítimos. Esse tipo de ataque pode paralisar o funcionamento de sistemas críticos como freios e direção.
- **Fuzzy Attack:** é caracterizado pela injeção de mensagens aleatórias ou malformadas no barramento CAN com o objetivo de provocar comportamentos inesperados ou travamentos nos módulos ECUs (*Electronic Control Units*).
- **Spoofing:** envolve a falsificação de mensagens legítimas. Por exemplo, um atacante pode enviar sinais falsos de RPM ou marcha (*gear*) para o painel de instrumentos, induzindo o condutor ao erro ou enganando outros sistemas automatizados do veículo.

Para explorar esses cenários, este trabalho utiliza dois conjuntos de dados realistas que contêm exemplos desses ataques, aplicados em ambientes controlados e com infraestrutura veicular real. A utilização desses dados permite simular condições próximas ao ambiente real de operação, possibilitando o treinamento de modelos de detecção mais robustos. O objetivo principal é construir um sistema que, ao observar o tráfego da rede CAN, consiga distinguir comportamentos normais de

intrusões com alta precisão, contribuindo para a proteção dos veículos conectados no contexto da IoT.

III. TRABALHOS RELACIONADOS

Um trabalho relevante na área é “A Hybrid Deep Learning Based Intrusion Detection System Using Spatial-Temporal Representation of In-Vehicle Network Traffic” [4], publicado em *Vehicular Communications*. Os autores propõem o sistema *HyDL-IDS*, que combina redes neurais convolucionais (*CNN*) e *Long Short-Term Memory (LSTM)* para extrair, respectivamente, características espaciais e temporais do tráfego CAN. Essa abordagem busca superar limitações comuns em *IDSs* baseados em aprendizado de máquina, como a dependência do design manual de *features* e as elevadas taxas de falsos alarmes. O sistema foi validado utilizando o *Car-Hacking Dataset*, obtendo resultados expressivos, com precisão próxima a 100% na detecção de ataques de *DoS* e *spoofing*, e desempenho superior a métodos tradicionais e arquiteturas isoladas de *CNN* ou *LSTM*.

Outro trabalho relevante é “*CICIoV2024: Advancing Realistic IDS Approaches Against DoS and Spoofing Attack in IoV CAN Bus*” [5], publicado na revista *Internet of Things*. Diferente de muitos estudos baseados apenas em simulações, os autores propuseram e disponibilizaram o *CICIoV2024*, um conjunto de dados de *benchmark* construído a partir de experimentos conduzidos em um veículo real (Ford 2019) com todas as *ECUs* intactas. O *dataset* contempla tráfego benigno e malicioso, abrangendo ataques de *DoS* e múltiplas variantes de *spoofing*, coletados via porta *OBD-II*. Além de disponibilizar os dados em diferentes representações (binária, decimal e hexadecimal), o estudo também avaliou o desempenho de algoritmos de aprendizado de máquina, como *Logistic Regression*, *Random Forest*, *Adaboost* e *Deep Neural Network*, em tarefas de classificação binária e multiclasse. Os resultados mostraram que ataques de *DoS* foram facilmente detectados por todos os modelos, enquanto a tarefa de classificação mais granular (seis classes) obteve os melhores resultados com *DNN* e *Random Forest*, alcançando acurácia de até 0,96. O trabalho representa uma contribuição importante ao fornecer um *dataset* realista e abrangente, estabelecendo uma nova base para pesquisas em segurança de redes *IoV*.

IV. BASES DE DADOS PARA MODELAGEM E DETECÇÃO DE ATAQUES

Para a construção e validação do modelo de detecção, foram utilizados dois conjuntos de dados complementares: o *Car-Hacking Dataset* [3] e o *CIC IoV 2024 Dataset* [6]. Ambos simulam tráfegos veiculares reais no contexto da IoT e apresentam diferentes tipos de ataques e mensagens normais. Outros *datasets* relevantes para sistemas de detecção de intrusão incluem o *UNSW-NB15* [7] e o *CICIDS2017* [8].

CIC IoV 2024 Dataset

Este *dataset* foi coletado em um veículo real (Ford 2019) com ataques via *CAN-BUS*, simulando um ambiente realista da Internet dos Veículos [6]. A Tabela II apresenta a distribuição das amostras coletadas.

TABLE I
DISTRIBUIÇÃO DE MENSAGENS NO CAR-HACKING DATASET

Classe	Quantidade de Amostras
BENIGN (Normal)	15.226.830
DoS	587.521
Fuzzy	491.847
Spoofing - Gear	597.252
Spoofing - RPM	654.897
Total	17.558.347

TABLE II
DISTRIBUIÇÃO DE MENSAGENS NO CIC IOV 2024 DATASET

Classe	Quantidade de Amostras
BENIGN (Normal)	1.223.737
DoS	74.663
GAS	9.991
RPM	54.900
SPEED	24.951
STEERING_WHEEL	19.977
Total	1.408.219

Car-Hacking Dataset

Este conjunto contém simulações de ataques de injeção de mensagens sobre a rede *CAN*, com mais de 17 milhões de mensagens no total [3]. A Tabela I apresenta a distribuição de amostras considerando tanto os tráfegos normais quanto os distintos tipos de ataques.

V. MODELAGEM COM APRENDIZADO DE MÁQUINA

Pré-processamento e Balanceamento dos Dados

Para a construção do modelo de detecção de intrusões, utilizou-se como base o *Car-Hacking Dataset* [3], devido à sua grande quantidade de amostras. Posteriormente, foram incorporadas amostras adicionais das classes BENIGN e DoS provenientes do *CIC IoV 2024 Dataset* [6], a fim de enriquecer a diversidade dos dados normais e dos ataques de negação de serviço.

Após a fusão dos conjuntos, foi realizado um balanceamento das classes para evitar viés no treinamento, conforme recomendado por He e Garcia [9]. A distribuição final das classes ficou conforme a Tabela III:

TABLE III
DISTRIBUIÇÃO FINAL DE AMOSTRAS BALANCEADAS PARA TREINAMENTO

Classe	Quantidade de Amostras
BENIGN	1.000.000
DoS	662.184
RPM	654.897
gear	597.252
Fuzzy	491.846
Total	3.406.179

As classes foram codificadas numericamente utilizando o *LabelEncoder* do *Scikit-learn*, e os dados foram divididos em 80% para treinamento e 20% para teste. Para garantir a robustez na avaliação do modelo, foi adotada validação cruzada estratificada, conforme recomendado por Géron [10].




Fig. 1. Curva de Loss de Treino e Teste - MLPClassifier

Arquitetura do Modelo

Foi utilizado o `MLPClassifier` (Perceptron Multicamadas) do *Scikit-learn*, onde foram exploradas diferentes combinações de hiperparâmetros. Após testes sucessivos, a configuração ideal encontrada foi:

- `hidden_layer_sizes = (30, 30)`
- `activation = 'relu'`
- `solver = 'adam'`
- `alpha = 0.0001`
- `max_iter = 1`
- `warm_start = True`
- `random_state = 42`

Essa configuração permitiu treinar o modelo de forma iterativa durante 25 épocas, armazenando os resultados a cada iteração.

VI. AVALIAÇÃO EXPERIMENTAL E ANÁLISE DOS RESULTADOS

Esta seção apresenta os resultados obtidos com o modelo `MLPClassifier` para a detecção de intrusões em redes *CAN*, utilizando as métricas de desempenho e visualizações que demonstram a eficácia da abordagem proposta.

A. Curvas de Treinamento e Validação

As Figuras 1 e 2 ilustram o comportamento do `loss` e da acurácia do modelo durante as 20 épocas de treinamento e teste.

A Figura 1 mostra que a `loss` diminui rapidamente nas primeiras épocas, estabilizando-se em valores baixos tanto para o conjunto de treino quanto para o conjunto de teste. Isso indica que o modelo está aprendendo de forma eficiente e generalizando bem para dados não vistos. A proximidade das curvas de treino e teste sugere que o modelo não está sofrendo de *overfitting* significativo [11].

De forma similar, a Figura 2 demonstra que a acurácia do modelo atinge valores elevados rapidamente e se mantém consistentemente acima de 0.99 para ambos os conjuntos. Essa alta acurácia, combinada com a convergência das curvas de




Fig. 2. Curva de Acurácia de Treino e Teste - MLPClassifier




Fig. 3. Matriz de Confusão do Modelo

treino e teste, reforça a capacidade do modelo em classificar corretamente as mensagens, distinguindo entre comportamentos normais e anômalos [11].

B. Matriz de Confusão

A Figura 3 apresenta a matriz de confusão do modelo no conjunto de testes. Esta matriz é fundamental para entender o desempenho do classificador em relação a cada classe específica, detalhando os acertos (verdadeiros positivos) e erros (falsos positivos/negativos) [12].

Observa-se que o modelo possui um desempenho geral excepcional, com a esmagadora maioria das amostras sendo corretamente classificada, o que é evidenciado pelos altos valores na diagonal principal da matriz de confusão. Os erros de classificação são mínimos em comparação com o volume total de acertos. A classe *BENIGN*, representando o tráfego normal, apresenta uma taxa de verdadeiros positivos extremamente alta (199.836). No entanto, um número reduzido de amostras benignas foi erroneamente classificado como algum tipo de ataque, principalmente como *gear* (109 casos) e *Fuzzy* (51

casos). Em um sistema de detecção de intrusão, esses *falsos positivos* (*alarmes falsos*), embora indesejáveis, são muitas vezes considerados mais aceitáveis do que a falha em detectar um ataque real.

C. Métricas de Classificação Detalhadas

A Tabela IV sumariza as métricas de *precision*, *recall*, *F1-score* e *support* para cada classe, fornecendo uma visão detalhada do desempenho do modelo.

TABLE IV
RELATÓRIO DE CLASSIFICAÇÃO DETALHADO

Classe	Precision	Recall	F1-Score	Support
BENIGN	0.99952	0.99918	0.99935	200000
DoS	0.99998	1.00000	0.99999	132437
Fuzzy	0.99948	0.99904	0.99926	98369
RPM	0.99998	0.99998	0.99998	141960
gear	0.99909	1.00000	0.99954	119450
Accuracy	0.0.99962 (Total: 681236)			

A análise da Tabela IV confirma o desempenho excepcional do modelo. A acurácia global de 0.99962 (aproximadamente 99.96%) demonstra que a esmagadora maioria das previsões está correta. As classes de ataque apresentam métricas de *F1-Score* extremamente altas, como 0.99998 para *RPM*, 0.99999 para *DoS* e 0.99954 para *gear*, indicando uma capacidade de detecção quase perfeita [13].

VII. CONCLUSÃO

A crescente integração de veículos à *Internet das Coisas* (*IoT*) – culminando na *Internet of Vehicles* (*IoV*) – embora prometa avanços significativos em segurança e eficiência, introduz desafios complexos de segurança cibernética, especialmente na vulnerável arquitetura da rede *CAN*. O protocolo *CAN*, projetado sem mecanismos intrínsecos de segurança como autenticação e criptografia, expõe os veículos modernos a uma série de ataques cibernéticos, como *DoS*, *Fuzzy* e *Spoofing*, que podem comprometer sistemas críticos e a segurança dos ocupantes. Diante desse cenário, este trabalho propôs e avaliou uma abordagem baseada em *machine learning* para a detecção de intrusões em tempo real na rede *CAN*.

Em síntese, os resultados obtidos demonstram que a aplicação de técnicas de *machine learning*, especificamente um *MLPClassifier* otimizado, é uma solução promissora e altamente eficaz para o desenvolvimento de sistemas de detecção de intrusões em redes *CAN* veiculares. Este trabalho contribui significativamente para a proteção da crescente frota de veículos conectados, mitigando os riscos cibernéticos e reforçando a segurança no contexto da *IoV*.

REFERENCES

- [1] J. Liu, S. Zhang, W. Sun and Y. Shi, "In-Vehicle Network Attacks and Countermeasures: Challenges and Future Directions," in *IEEE Network*, vol. 31, no. 5, pp. 50-58, 2017, doi: 10.1109/MNET.2017.1600257. keywords: intelligent vehicles;Ports (Computers);Network security;Telematics;Vehicular ad hoc networks;Wireless networks;Actuators,
- [2] H. Zeltwanger, "CAN standard review: Changes and enhancements of the ISO 11898," SAE Technical Paper, 2000.

- [3] E. Seo, H. M. Song, and H. K. Kim, "GIDS: GAN based Intrusion Detection System for In-Vehicle Network," in *Proc. 16th Annual Conf. on Privacy, Security and Trust (PST)*, Aug. 2018, pp. 1–6, doi: 10.1109/PST.2018.8514157.
- [4] Wei Lo, Hamed Alqahtani, Kutub Thakur, Ahmad Almadhor, Subhash Chander, Gulshan Kumar, A hybrid deep learning based intrusion detection system using spatial-temporal representation of in-vehicle network traffic, *Vehicular Communications*, Volume 35, 2022, 100471, ISSN 2214-2096, <https://doi.org/10.1016/j.vehcom.2022.100471>. (<https://www.sciencedirect.com/science/article/pii/S2214209622000183>)
- [5] Euclides Carlos Pinto Neto, Hamideh Taslimasa, Sajjad Dadkhah, Shahrear Iqbal, Pulei Xiong, Taufiq Rahman, Ali A. Ghorbani, *CICIoV2024: Advancing realistic IDS approaches against DoS and spoofing attack in IoV CAN bus*, *Internet of Things*, Volume 26, 2024, 101209, ISSN 2542-6605, <https://doi.org/10.1016/j.iot.2024.101209>. (<https://www.sciencedirect.com/science/article/pii/S2542660524001501>)
- [6] E. C. P. Neto et al., "CICIoV2024: Advancing realistic IDS approaches against DoS and spoofing attack in IoV CAN bus," *Internet of Things*, vol. 26, p. 101209, 2024, doi: 10.1016/j.iot.2024.101209.
- [7] N. Moustafa and J. Slay, "UNSW-NB15: A comprehensive data set for building next-generation intrusion detection systems," in *Proc. Military Communications and Information Systems Conference (MilCIS)*, 2015, pp. 1–6, doi: 10.1109/MilCIS.2015.7348942.
- [8] I. Sharafaldin, A. H. Lashkari, and A. A. Ghorbani, "Toward a new dataset for intrusion detection systems," *Future Generation Computer Systems*, vol. 100, pp. 20–27, 2019, doi: 10.1016/j.future.2018.06.004.
- [9] H. He and E. A. Garcia, "Learning from imbalanced data," *IEEE Transactions on Knowledge and Data Engineering*, vol. 21, no. 9, pp. 1263–1284, 2009, doi: 10.1109/TKDE.2008.239.
- [10] A. Géron, *Hands-On Machine Learning with Scikit-Learn, Keras, and TensorFlow: Concepts, Tools, and Techniques to Build Intelligent Systems*, 2nd ed. Sebastopol, CA, USA: O'Reilly Media, 2019.
- [11] Medium - Data Science, "Learning curve to identify overfitting/underfitting problems," 2021. [Online].
- [12] T. Fawcett, "An introduction to ROC analysis," *Pattern Recognition Letters*, vol. 27, no. 8, pp. 861–874, 2006, doi: 10.1016/j.patrec.2005.10.010.
- [13] T. Saito and M. Rehmsmeier, "The Precision-Recall Plot Is More Informative than the ROC Plot When Evaluating Binary Classifiers on Imbalanced Datasets," *PLOS ONE*, vol. 10, no. 3, pp. 1–21, 2015, doi: 10.1371/journal.pone.0118432.
- [14] H. M. Song, J. Woo, and H. K. Kim, "In-vehicle network intrusion detection using deep convolutional neural network," *Vehicular Communications*, vol. 21, p. 100198, 2020.
- [15] Medium - Data Science, "Learning curve to identify overfitting/underfitting problems," 2021. [Online].
- [16] J. R. Claro, *Sistemas IDS e IPS – Estudo e Aplicação de Ferramenta Open Source em Ambiente Linux*, Monografia de Graduação, Universidade de Passo Fundo, Passo Fundo, Brazil, 2015.