



**UNIVERSIDADE FEDERAL DO RECÔNCAVO DA BAHIA - UFRB
CENTRO DE CIÊNCIAS EXATAS E TECNOLÓGICAS - CETEC
BACHARELADO EM ENGENHARIA DA COMPUTAÇÃO**

JOÃO PEDRO DALTRO MARQUES

Detecção de Intrusões em Redes CAN de Sistemas Veiculares:
Comparação de Modelos Supervisionados para Classificação
Multiclasse

**CRUZ DAS ALMAS - BA
2026**

JOÃO PEDRO DALTRO MARQUES

Detecção de Intrusões em Redes CAN de Sistemas Veiculares:
Comparação de Modelos Supervisionados para Classificação
Multiclasse

Trabalho de Conclusão de Curso submetido à Universidade Federal do Recôncavo da Bahia, como requisito necessário para obtenção do grau de Bacharel em Engenharia da Computação

Cruz das Almas, 2026

UNIVERSIDADE FEDERAL DO RECÔNCAVO DA BAHIA

JOÃO PEDRO DALTRO MARQUES

Esta Monografia foi julgada adequada para a obtenção do título de Bacharel em Engenharia da Computação, sendo aprovada em sua forma final pela banca examinadora:

Orientador(a): Prof. Dr. José Valetim
Universidade Federal do Recôncavo da Bahia
- UFRB

Avaliador(a) 1: Prof. Dr. Gildeberto de
Souza Cardoso
Universidade Federal do Recôncavo da Bahia
- UFRB

Avaliador(a) 2: Prof. Dr.
Universidade Federal do Recôncavo da Bahia
- UFRB

Cruz das Almas, 2026

Agradecimentos

Primeiramente, agradeço a Deus por todas as bênçãos concedidas, por guiar meus passos e iluminar meu caminho em todos os momentos da minha vida.

À minha família, expresso minha profunda gratidão aos meus pais, Ubiratan e Valmira, por seu apoio incondicional, amor e sacrifício. Eles foram fundamentais em minha jornada acadêmica, proporcionando as condições necessárias para que eu pudesse estudar e me desenvolver como pessoa. Agradeço também ao meu irmão, Filipe, por ser um exemplo e compartilhar suas experiências de vida, me orientando e incentivando a ser sempre melhor. À minha irmã, Vanessa, agradeço por seu amor incondicional e por estar ao meu lado, independentemente das circunstâncias.

Aos meus primos Jade, Milena e José, expresso minha gratidão pelo apoio emocional que sempre me ofereceram, incentivando-me a continuar, independentemente dos desafios que enfrentei.

Aos meus amigos de longa data, Daniel, Guilherme, Gustavo Rabelo, Gustavo Ravi, Lucas e Luciano, sou imensamente grato por me acolherem na universidade e por estarem ao meu lado em todos os momentos, compartilhando experiências, aprendizados e apoio mútuo. Nossa união e sinceridade foram fundamentais para enfrentarmos juntos os desafios acadêmicos e pessoais.

Ao meu orientador José, expresso minha sincera gratidão por seus conselhos, paciência e orientação ao longo deste período. Sua ajuda não se limitou apenas a este trabalho, mas também foi fundamental em minha iniciação científica, fornecendo direção e apoio.

Por fim, dedico um agradecimento especial à pessoa que é minha maior inspiração e amor neste mundo, meu irmão gêmeo, João Marcelo. Sua presença ao meu lado, compartilhando momentos de risadas, afeto e amor, tem sido essencial em minha vida desde o momento em que chegamos juntos a este mundo.

A todos vocês, meu profundo e eterno agradecimento, **João Pedro Daltro Marques**

*“É o seu lugar no mundo; é a sua vida.
Vá em frente, faça tudo o que puder com ela
e torne-a a vida que você quer viver”
(Mae Jemison)*

Resumo

Este trabalho investiga a detecção de intrusões em redes CAN de sistemas veiculares no contexto da Internet of Vehicles (IoVT). O objetivo foi comparar quatro modelos supervisionados de aprendizado de máquina para classificação multiclasse de tráfego CAN: Regressão Logística, SVM, MLP e XGBoost. O estudo utilizou um conjunto final alinhado e limpo com cinco classes (BENIGN, DoS, Fuzzy, GEAR e RPM), adotando como base canônica os artefatos finais de avaliação em `results/metrics/*_final_clean`.

As métricas principais de comparação foram accuracy, precision macro, recall macro e F1 macro, complementadas por análise por classe. Os resultados mostraram desempenho global superior do XGBoost (accuracy 0.99998; F1 macro 0.99998), seguido do MLP (accuracy 0.99908; F1 macro 0.99905). Regressão Logística e SVM apresentaram desempenho inferior aos dois melhores modelos, embora com resultados consistentes no cenário avaliado. A classe Fuzzy foi a mais desafiadora para todos os classificadores, enquanto GEAR e RPM apresentaram separação quase perfeita.

Como contribuição, o trabalho oferece uma comparação reproduzível entre modelos para IDS em CAN, com rastreabilidade dos resultados e alinhamento entre metodologia e avaliação final.

Palavras-chave: IDS, rede CAN, IoVT, aprendizado de máquina, detecção de intrusões.

Abstract

This work investigates intrusion detection in in-vehicle CAN networks within the Internet of Vehicles (IoVT) context. The main objective was to compare four supervised machine learning models for multiclass CAN traffic classification: Logistic Regression, SVM, MLP, and XGBoost. The study used a final aligned and cleaned dataset with five classes (BENIGN, DoS, Fuzzy, GEAR, and RPM), adopting the final evaluation artifacts in `results/metrics/*_final_clean` as the canonical source.

The main comparison metrics were accuracy, macro precision, macro recall, and macro F1, supported by class-level analysis. Results show that XGBoost achieved the best overall performance (accuracy 0.99998; macro F1 0.99998), followed by MLP (accuracy 0.99908; macro F1 0.99905). Logistic Regression and SVM performed below the two top models, although both remained consistent in the evaluated scenario. The Fuzzy class was the most challenging class across all classifiers, while GEAR and RPM were almost perfectly separable.

As a contribution, this work provides a reproducible CAN IDS model comparison with traceable results and strong alignment between methodology and final evaluation.

Keywords: IDS, CAN network, IoVT, machine learning, intrusion detection.

Lista de ilustrações

Lista de tabelas

Tabela 1 – Configuracao dos conjuntos de treino e teste por modelo	32
Tabela 2 – Comparacao principal entre os modelos (resultados finais limpos) . . .	35

Lista de abreviaturas e siglas

CAN: Controller Area Network

DLC: Data Length Code

ECU: Electronic Control Unit

F1: F1-Score

FN: Falso Negativo

FP: Falso Positivo

IDS: Intrusion Detection System

IoT: Internet of Things

IoVT: Internet of Vehicles

MLP: Multilayer Perceptron

SVM: Support Vector Machine

VN: Verdadeiro Negativo

VP: Verdadeiro Positivo

XGB: Extreme Gradient Boosting

Sumário

1	INTRODUÇÃO	21
1.1	Objetivo	23
1.1.1	Objetivo Geral	23
1.1.2	Objetivos Específicos	23
1.2	Organização do Trabalho	24
2	FUNDAMENTACAO TEORICA	25
2.1	Rede CAN no Contexto Veicular	25
2.2	Ataques Considerados	25
2.2.1	DoS	25
2.2.2	Fuzzy	25
2.2.3	Spoofing de Sinais (GEAR e RPM)	25
2.3	IDS Baseado em Aprendizado Supervisionado	26
2.4	Metricas de Avaliacao	26
2.4.1	Acuracia	26
2.4.2	Precisao	26
2.4.3	Recall	26
2.4.4	F1-Score	27
2.4.5	Media Macro	27
2.5	Sintese do Capitulo	27
3	TRABALHOS RELACIONADOS	29
3.1	IDS com Aprendizado de Maquina	29
3.2	Pre-processamento e Selecao de Atributos	29
3.3	Contexto CAN e IoVT	29
3.4	Lacunas Identificadas	30
3.5	Posicionamento deste Trabalho	30
4	METODOLOGIA	31
4.1	Base de Dados e Recorte Experimental	31
4.2	Pipeline de Processamento	31
4.3	Modelos Avaliados	31
4.4	Configuracao de Treino e Teste	32
4.5	Metricas de Avaliacao	32
4.6	Reprodutibilidade e Fontes Canonicas	33

5	RESULTADOS E DISCUSSÕES	35
5.1	Comparacao Principal entre Modelos	35
5.2	Analise por Classe	35
5.3	Discussao dos Resultados	36
5.4	Sintese do Capitulo	36
6	CONSIDERAÇÕES FINAIS	37
6.1	Resposta a Pergunta de Pesquisa	37
6.2	Principais Achados	37
6.3	Limitacoes	37
6.4	Trabalhos Futuros	38
	REFERÊNCIAS	39
	APÊNDICES	41
	APÊNDICE A – REPOSITÓRIO NO GITHUB	43

1 Introdução

A indústria automotiva atravessa uma das maiores transformações de sua história com a incorporação de tecnologias digitais, sistemas embarcados e recursos avançados de conectividade. Veículos modernos deixaram de ser compostos exclusivamente por componentes mecânicos e passaram a integrar dezenas de unidades eletrônicas de controle (Electronic Control Units - ECUs), sensores, atuadores e módulos de comunicação responsáveis por funções que vão desde o controle do motor até sistemas avançados de assistência ao condutor. Essa evolução possibilitou o desenvolvimento de veículos mais seguros, eficientes e inteligentes, estabelecendo as bases para o conceito da Internet of Vehicles (IoVT), no qual veículos trocam informações entre si, com infraestruturas inteligentes, dispositivos móveis e serviços em nuvem.

A Internet of Vehicles representa uma evolução da Internet das Coisas (IoT) aplicada ao setor automotivo. Nesse paradigma, veículos tornam-se elementos ativos de uma rede altamente conectada, compartilhando continuamente informações relacionadas ao tráfego, condições da via, localização, diagnósticos do veículo e diversos outros serviços inteligentes. Essa comunicação possibilita aplicações como direção autônoma, manutenção preditiva, gerenciamento inteligente de frotas, sistemas cooperativos de transporte e monitoramento remoto. Entretanto, ao mesmo tempo em que amplia as funcionalidades disponíveis, essa conectividade aumenta significativamente a superfície de ataque dos veículos modernos, tornando a segurança cibernética um dos principais desafios da indústria automotiva.

Grande parte da comunicação interna entre os componentes eletrônicos do veículo ocorre por meio do barramento Controller Area Network (CAN), protocolo desenvolvido para permitir a troca rápida e confiável de mensagens entre as ECUs. O protocolo CAN tornou-se o padrão predominante na indústria automotiva devido à sua simplicidade, baixo custo, robustez e capacidade de operar em ambientes sujeitos a interferências eletromagnéticas. Por meio desse barramento, informações críticas relacionadas ao motor, sistema de freios, transmissão, direção, airbag, painel de instrumentos e diversos outros módulos são transmitidas continuamente durante toda a operação do veículo.

Embora eficiente para comunicação em tempo real, o protocolo CAN foi desenvolvido em uma época em que veículos operavam de forma isolada, sem a necessidade de comunicação com redes externas. Dessa forma, mecanismos de segurança, como autenticação de mensagens, criptografia, controle de acesso e verificação da identidade dos dispositivos, não foram incorporados ao protocolo original. Como consequência, qualquer ECU conectada ao barramento pode transmitir mensagens que serão aceitas pelos demais módulos, desde que utilizem um identificador válido. Essa característica torna a rede

CAN vulnerável a diferentes tipos de ataques capazes de comprometer tanto a segurança cibernética quanto a segurança funcional do veículo.

Nos últimos anos, diversos estudos demonstraram que atacantes podem explorar essas vulnerabilidades para realizar diferentes formas de ataque ao barramento CAN. Entre os ataques mais comuns destacam-se os ataques de negação de serviço (Denial of Service - DoS), que saturam o barramento com mensagens de alta prioridade e impedem a comunicação legítima entre as ECUs; ataques de spoofing, nos quais mensagens falsas são injetadas simulando módulos legítimos; ataques Fuzzy, caracterizados pela inserção de quadros CAN com identificadores aleatórios; e ataques específicos de falsificação de parâmetros críticos, como velocidade do motor (RPM) e posição da transmissão (Gear). A execução bem-sucedida desses ataques pode provocar desde falhas operacionais até alterações no comportamento do veículo, comprometendo sua confiabilidade e colocando em risco a segurança dos ocupantes.

A crescente sofisticação dos ataques cibernéticos evidencia que mecanismos tradicionais de proteção, como firewalls e autenticação em gateways, não são suficientes para garantir a segurança de sistemas automotivos modernos. Em muitos casos, o atacante pode obter acesso físico à rede CAN por meio da porta OBD-II ou explorar interfaces externas, como Bluetooth, Wi-Fi, sistemas multimídia e módulos telemáticos, permitindo a injeção de mensagens maliciosas diretamente no barramento. Nesse cenário, torna-se fundamental desenvolver mecanismos capazes de identificar rapidamente comportamentos anômalos durante a comunicação entre os módulos eletrônicos do veículo.

Entre as soluções propostas para enfrentar esse desafio, os Sistemas de Detecção de Intrusão (Intrusion Detection Systems - IDS) destacam-se como uma das principais abordagens de segurança em redes automotivas. Diferentemente dos mecanismos preventivos, os IDS têm como objetivo monitorar continuamente o tráfego da rede e identificar atividades suspeitas ou padrões incompatíveis com o comportamento normal do sistema. Uma vez detectada uma possível intrusão, o sistema pode emitir alertas ou acionar mecanismos de resposta capazes de minimizar os impactos do ataque.

Nos últimos anos, técnicas de aprendizado de máquina têm sido amplamente investigadas para aplicação em sistemas de detecção de intrusão. Diferentemente das abordagens baseadas exclusivamente em assinaturas, modelos supervisionados são capazes de aprender padrões de comunicação presentes nos dados e identificar diferentes categorias de ataques mesmo em cenários complexos de classificação. Além disso, esses modelos apresentam potencial para detectar comportamentos anômalos com elevada precisão, tornando-se uma alternativa promissora para aplicações em segurança cibernética automotiva.

Entretanto, a construção de modelos confiáveis depende diretamente da qualidade dos dados utilizados durante o treinamento. Bases de dados provenientes de diferentes fontes frequentemente apresentam inconsistências, formatos distintos, redundâncias e distribuições

desbalanceadas entre as classes, fatores que podem comprometer significativamente o desempenho dos algoritmos de aprendizado de máquina. Dessa forma, etapas de pré-processamento, alinhamento das características, tratamento dos dados e balanceamento das classes tornam-se fundamentais para garantir uma avaliação justa e representativa dos modelos desenvolvidos.

Neste trabalho é investigada a aplicação de técnicas supervisionadas de aprendizado de máquina para a detecção de intrusões em redes CAN automotivas. Para isso, foi construído um conjunto de dados alinhado e pré-processado contendo as classes BENIGN, DoS, Fuzzy, GEAR e RPM, obtido a partir da integração de bases públicas amplamente utilizadas na literatura. Sobre esse conjunto de dados são avaliados quatro modelos de classificação: Regressão Logística, Support Vector Machine (SVM), Multilayer Perceptron (MLP) e eXtreme Gradient Boosting (XGBoost). O desempenho dos modelos é analisado por meio de métricas clássicas de classificação, incluindo acurácia, precisão, revocação, F1-score e curvas ROC, permitindo comparar sua capacidade de identificar corretamente diferentes categorias de ataques em um cenário de classificação multiclasse.

Os resultados obtidos contribuem para a compreensão da aplicabilidade de técnicas de aprendizado de máquina na segurança cibernética automotiva, fornecendo uma análise comparativa entre diferentes algoritmos supervisionados e evidenciando suas vantagens, limitações e potencial de utilização em sistemas de detecção de intrusão para redes CAN.

1.1 Objetivo

1.1.1 Objetivo Geral

O objetivo geral deste trabalho é desenvolver e avaliar um sistema de detecção de intrusões para redes CAN de sistemas veiculares, utilizando técnicas supervisionadas de aprendizado de máquina, a fim de comparar o desempenho de diferentes modelos na identificação de tráfego legítimo e de ataques cibernéticos em um cenário de classificação multiclasse da Internet of Vehicles (IoVT).

1.1.2 Objetivos Específicos

Para alcançar o objetivo geral proposto, foram definidos os seguintes objetivos específicos:

- Realizar uma revisão bibliográfica sobre segurança cibernética automotiva, Internet of Vehicles (IoVT), redes CAN e Sistemas de Detecção de Intrusão (IDS);
- Investigar os principais ataques direcionados às redes CAN e seus impactos sobre a segurança e o funcionamento dos sistemas veiculares;

- Construir um conjunto de dados unificado a partir de bases públicas, realizando o alinhamento das características, tratamento dos dados e pré-processamento necessário para o treinamento dos modelos;
- Avaliar o impacto das etapas de pré-processamento na qualidade do conjunto de dados utilizado para o desenvolvimento dos modelos;
- Implementar e treinar diferentes algoritmos supervisionados de aprendizado de máquina para a detecção e classificação de intrusões em redes CAN;
- Comparar o desempenho dos modelos por meio de métricas de classificação, incluindo acurácia, precisão, revocação e F1-score;
- Analisar o desempenho individual de cada classe de ataque, identificando as categorias de maior dificuldade de classificação;
- Identificar o modelo que apresenta o melhor desempenho global para aplicação em sistemas de detecção de intrusão em redes CAN.

1.2 Organização do Trabalho

Este trabalho está organizado em seis capítulos. O Capítulo 1 apresenta a introdução, abordando a contextualização do problema, a motivação, os objetivos da pesquisa e a organização do trabalho. No Capítulo 2 é apresentada a fundamentação teórica, contemplando os principais conceitos relacionados à Internet of Vehicles (IoVT), às redes CAN, à segurança cibernética automotiva, aos sistemas de detecção de intrusão e às técnicas de aprendizado de máquina utilizadas neste estudo. O Capítulo 3 apresenta os trabalhos relacionados, discutindo pesquisas recentes sobre detecção de intrusões em redes CAN e evidenciando as principais contribuições da literatura.

No Capítulo 4 é descrita a metodologia empregada no desenvolvimento do trabalho, incluindo a caracterização dos conjuntos de dados utilizados, as etapas de pré-processamento, a construção da base final, os modelos de aprendizado de máquina avaliados, as métricas de desempenho adotadas e o ambiente experimental. O Capítulo 5 apresenta os resultados obtidos e realiza uma análise comparativa entre os modelos, considerando tanto as métricas globais quanto o desempenho individual de cada classe de ataque. Por fim, o Capítulo 6 apresenta as conclusões do trabalho, destacando as principais contribuições da pesquisa, suas limitações e sugestões para trabalhos futuros.

2 Fundamentacao Teorica

Este capitulo apresenta os conceitos que sustentam o trabalho: rede CAN em sistemas veiculares, tipos de ataque considerados no recorte experimental, fundamentos de IDS baseado em aprendizado supervisionado e metricas usadas na comparacao final.

2.1 Rede CAN no Contexto Veicular

A Controller Area Network (CAN) e um barramento de comunicacao serial amplamente usado em veiculos para troca de mensagens entre ECUs. Em vez de um modelo cliente-servidor tradicional, a comunicacao ocorre por difusao no barramento, e cada mensagem e identificada por um CAN ID. Esse desenho favorece robustez e baixo custo, mas tambem cria desafios de seguranca, pois um no comprometido pode injetar mensagens que afetam varios subsistemas.

No recorte deste trabalho, cada amostra e representada por atributos derivados da mensagem CAN, incluindo DLC e bytes de payload. O dataset final contempla cinco classes: BENIGN, DoS, Fuzzy, GEAR e RPM.

2.2 Ataques Considerados

2.2.1 DoS

No ataque DoS em CAN, o barramento e sobrecarregado com mensagens de alta frequencia, reduzindo a disponibilidade para trafego legitimo. Em ambiente veicular, isso pode degradar a latencia de sinais criticos e comprometer funcoes de controle.

2.2.2 Fuzzy

Fuzzy refere-se a injecoes com padroes aleatorios ou semantica inconsistente no payload. Esse tipo de ataque tende a ser mais desafiador para classificacao porque pode apresentar fronteira menos nitida entre comportamento legitimo e malicioso.

2.2.3 Spoofing de Sinais (GEAR e RPM)

Nos ataques de spoofing, mensagens validas do ponto de vista de formato sao injetadas com conteudo falso para simular estados incorretos do sistema. Neste trabalho, o problema inclui spoofing associado a GEAR e RPM.

2.3 IDS Baseado em Aprendizado Supervisionado

Um IDS supervisionado aprende uma funcao de mapeamento entre atributos de entrada e classes de saida a partir de dados rotulados. No contexto deste trabalho, essa formulacao e multiclasse e foi aplicada a quatro modelos:

- Regressao Logistica;
- SVM (LinearSVC);
- MLP;
- XGBoost.

A comparacao entre modelos foi realizada no mesmo recorte de classes, com artefatos finais padronizados em `classification_report` e `run_summary`.

2.4 Metricas de Avaliacao

As metricas utilizadas no comparativo principal sao `accuracy`, `precision macro`, `recall macro` e `F1 macro`, alem da analise por classe.

2.4.1 Acuracia

$$\text{Acuracia} = \frac{VP + VN}{VP + VN + FP + FN} \quad (2.1)$$

Expressa a proporcao total de previsoes corretas, mas isoladamente pode mascarar dificuldades em classes especificas.

2.4.2 Precisao

$$\text{Precisao} = \frac{VP}{VP + FP} \quad (2.2)$$

Indica a confiabilidade das predicoes positivas do modelo.

2.4.3 Recall

$$\text{Recall} = \frac{VP}{VP + FN} \quad (2.3)$$

Mede a capacidade de recuperar instancias positivas reais.

2.4.4 F1-Score

$$F1 = \frac{2 \cdot \text{Precisao} \cdot \text{Recall}}{\text{Precisao} + \text{Recall}} \quad (2.4)$$

Combina precisão e recall em uma única medida harmônica.

2.4.5 Média Macro

No cenário multiclasse, a média macro calcula a média aritmética simples da métrica em todas as classes. Esse critério foi adotado para evitar que classes com maior volume dominem a interpretação global.

2.5 Síntese do Capítulo

A fundamentação apresentada sustenta a estratégia metodológica e o critério de comparação usados no trabalho. Em especial, destaca-se que IDS em CAN deve ser analisado tanto por desempenho global quanto por classe, pois ataques como Fuzzy podem exigir maior capacidade de discriminação dos modelos.

3 *Trabalhos Relacionados*

Esta secao apresenta o panorama de pesquisas em IDS com aprendizado de maquina, com enfase em tres eixos: (i) deteccao em redes IoT e industriais, (ii) abordagens para dados desbalanceados e selecao de atributos, e (iii) aplicacoes em contexto automotivo e CAN.

3.1 IDS com Aprendizado de Maquina

Diversos estudos mostram que classificadores supervisionados e modelos de ensemble sao competitivos para deteccao de intrusoes em cenarios multiclasse. Em geral, os resultados melhoram quando o pipeline combina limpeza de dados, selecao de atributos e ajuste de hiperparametros.

Trabalhos com Random Forest, Gradient Boosting e arquiteturas profundas reportam desempenho elevado em datasets publicos, especialmente quando o problema e formulado com classes bem definidas e protocolos de avaliacao claros. Por outro lado, muitos estudos utilizam configuracoes diferentes de split, balanceamento e preprocessamento, o que dificulta comparacao direta entre artigos.

3.2 Pre-processamento e Selecao de Atributos

A literatura destaca que o pre-processamento impacta diretamente as metricas finais. Tecnicas como remocao de inconsistencias, normalizacao, tratamento de classes minoritarias e selecao de variaveis reduzem ruido e aumentam estabilidade dos modelos.

Abordagens com RFE, filtros baseados em correlacao e estrategias de balanceamento (incluindo over-sampling e under-sampling) sao recorrentes. Entretanto, parte dos estudos nao detalha com precisao a ordem de aplicacao dessas tecnicas, ponto critico para reprodutibilidade e para evitar vazamento de informacao entre treino e teste.

3.3 Contexto CAN e IoVT

No ambiente veicular, a deteccao de intrusoes em barramento CAN possui caracteristicas proprias: mensagens curtas, alta frequencia de transmissao e forte dependencia do contexto operacional do veiculo. Nesses cenarios, o desafio nao e apenas obter acuracia alta, mas manter separacao confiavel entre classes de ataque com comportamento semelhante.

Os artigos auxiliares utilizados neste trabalho reforçam que classes relacionadas a perturbações no payload, como Fuzzy/spoofing, tendem a exigir modelos com maior capacidade de representação. Essa observação está alinhada ao comportamento encontrado nos resultados experimentais desta monografia.

3.4 Lacunas Identificadas

Apesar do volume de pesquisas, persistem lacunas relevantes:

- falta de padronização na comparação de modelos, dificultando reuso dos resultados;
- diferenças de protocolo experimental que tornam métricas de estudos distintos pouco comparáveis;
- baixa rastreabilidade de artefatos finais em parte da literatura, limitando reprodução exata.

3.5 Posicionamento deste Trabalho

Este trabalho se posiciona nessas lacunas ao adotar:

- comparação direta entre quatro modelos (Regressão Logística, SVM, MLP e XGBoost);
- fonte canônica única de resultados finais (diretórios `*_final_clean`);
- avaliação por métricas globais e por classe no mesmo recorte de dados.

Com essa estratégia, busca-se garantir consistência metodológica e clareza na interpretação dos resultados apresentados no capítulo seguinte.

4 Metodologia

Este capítulo descreve o pipeline experimental adotado para comparar modelos de aprendizado de máquina aplicados à detecção de intrusões em rede CAN no contexto IoVT. A metodologia foi definida para garantir reprodutibilidade e consistência entre os quatro modelos avaliados.

4.1 Base de Dados e Recorte Experimental

O estudo utilizou o arquivo consolidado e alinhado `carhacking_ciciov_benign_dos_aligned` gerado a partir da integração dos dados de Car-Hacking e CICIOV. O recorte final considera cinco classes: **BENIGN**, **DoS**, **Fuzzy**, **GEAR** e **RPM**.

Como parte do pré-processamento final, foram removidas 200665 amostras da fonte CARDt com $DLC < 8$, buscando padronizar o formato das mensagens utilizadas pelos classificadores. A modelagem final utilizou 9 atributos por amostra, conforme registrado nos arquivos `run_summary.json` de cada experimento.

4.2 Pipeline de Processamento

O fluxo adotado pode ser resumido nas seguintes etapas:

1. Carregamento do dataset final alinhado;
2. Aplicação do filtro de qualidade (remoção de $DLC < 8$);
3. Definição das classes alvo (**BENIGN**, **DoS**, **Fuzzy**, **GEAR**, **RPM**);
4. Separação em conjuntos de treino e teste;
5. Treinamento dos modelos supervisionados;
6. Avaliação por `classification_report` e acurácia final;
7. Exportação dos artefatos em `results/metrics/*_final_clean`.

4.3 Modelos Avaliados

Foram avaliados os seguintes modelos:

- Regressão Logística;

- SVM (LinearSVC);
- MLP (Multilayer Perceptron);
- XGBoost (XGBClassifier).

Cada modelo possui diretorio proprio de resultados contendo `run_summary.json`, `classification_report.txt`, `classification_report.csv`, matriz de confusao e curvas auxiliares de treinamento.

4.4 Configuracao de Treino e Teste

De acordo com os artefatos finais, as dimensoes de treino e teste foram as seguintes:

Tabela 1 – Configuracao dos conjuntos de treino e teste por modelo

Modelo	Treino	Teste
Regressao Logistica	200000 x 9	80000 x 9
SVM (LinearSVC)	150000 x 9	60000 x 9
MLP	2724943 x 9	681236 x 9
XGBoost	2724943 x 9	681236 x 9

Fonte: elaborada pelo autor com base em `run_summary.json`.

As diferencas de tamanho entre os conjuntos por modelo decorrem da estrategia de execucao registrada nos scripts finais de treinamento.

4.5 Metricas de Avaliacao

A comparacao principal entre modelos foi conduzida com as seguintes metricas:

- **Accuracy** no conjunto de teste;
- **Precision macro**;
- **Recall macro**;
- **F1 macro**;
- **Metricas por classe** (precision, recall e F1 para BENIGN, DoS, Fuzzy, GEAR e RPM).

As metricas foram extraidas de `classification_report.txt`. Para contexto experimental (formato dos dados e dimensoes), foi utilizado `run_summary.json`.

4.6 Reprodutibilidade e Fontes Canonicas

Para evitar divergencia de resultados no texto final, este trabalho adota como fonte canonica os diretorios:

- `results/metrics/logistic_regression_final_clean`
- `results/metrics/svm_final_clean`
- `results/metrics/mlp_final_clean`
- `results/metrics/xgboost_final_clean`

Relatorios anteriores agregados em `results/tcc_package/reports` sao utilizados apenas como apoio interpretativo, nao como fonte primaria dos numeros finais apresentados nos capitulos de resultados e conclusoes.

5 Resultados e Discussões

Este capítulo apresenta os resultados finais dos quatro modelos avaliados para detecção de intrusões em rede CAN: Regressão Logística, SVM, MLP e XGBoost. A base canônica utilizada corresponde aos artefatos `run_summary.json` e `classification_report.txt` dos diretórios `*_final_clean`.

5.1 Comparação Principal entre Modelos

A Tabela 2 consolida as métricas globais de comparação no conjunto de teste.

Tabela 2 – Comparação principal entre os modelos (resultados finais limpos)

Modelo	Accuracy	Precision Macro	Recall Macro	F1 Macro
Regressão Logística	0.97252	0.97587	0.96940	0.97235
SVM (LinearSVC)	0.94992	0.94689	0.95387	0.95000
MLP	0.99908	0.99937	0.99873	0.99905
XGBoost	0.99998	0.99999	0.99998	0.99998

Fonte: elaborada pelo autor com base em `classification_report.txt` dos experimentos finais.

Os resultados evidenciam superioridade de XGBoost no cenário avaliado, com desempenho quase perfeito nas métricas globais. O MLP apresentou resultado muito próximo e também altamente competitivo. Regressão Logística manteve desempenho forte para um modelo linear, enquanto o SVM ficou abaixo dos demais nas métricas globais.

5.2 Análise por Classe

Além das métricas agregadas, a avaliação por classe mostra que GEAR e RPM foram classes com separação quase perfeita na maior parte dos modelos. Em contrapartida, Fuzzy foi a classe mais desafiadora, concentrando as menores taxas de recall entre os quatro algoritmos.

No caso da Regressão Logística, o recall de Fuzzy foi 0.89292. No SVM, esse valor foi 0.88677, representando a pior taxa de recall entre os modelos. Para o MLP, o recall de Fuzzy subiu para 0.99368, e no XGBoost atingiu 0.99990.

Esse comportamento reforça que a dificuldade de classificação não está distribuída de forma uniforme entre classes. Assim, a discussão de desempenho por classe é indispensável para uma conclusão robusta sobre IDS multiclasse em CAN.

5.3 Discussao dos Resultados

Os resultados permitem destacar tres pontos principais.

Primeiro, ha um ganho expressivo ao migrar de modelos lineares para modelos nao lineares e de maior capacidade representacional, como MLP e XGBoost.

Segundo, mesmo quando a acuracia global e elevada, a avaliacao por classe continua necessaria para revelar classes mais sensiveis, como Fuzzy.

Terceiro, no recorte experimental adotado, XGBoost apresentou o melhor compromisso global, seguido de perto por MLP, tornando-se a referencia principal para recomendacao no capitulo de conclusoes.

5.4 Sintese do Capitulo

Com base na comparacao final, o ranking global de desempenho no cenario estudado foi:

1. XGBoost;
2. MLP;
3. Regressao Logistica;
4. SVM.

Essa sintese responde ao objetivo comparativo do trabalho e fundamenta a recomendacao final do modelo mais adequado para IDS em rede CAN no contexto deste experimento.

6 Considerações Finais

Este trabalho apresentou uma comparacao entre quatro modelos supervisionados para deteccao de intrusoes em rede CAN no contexto IoVT: Regressao Logistica, SVM, MLP e XGBoost. O estudo foi conduzido com base no conjunto final alinhado e limpo, com classes **BENIGN**, **DoS**, **Fuzzy**, **GEAR** e **RPM**, adotando como fonte canonica os artefatos finais em `results/metrics/*_final_clean`.

6.1 Resposta a Pergunta de Pesquisa

A pergunta de pesquisa buscou identificar qual modelo apresenta melhor desempenho multiclasse para IDS em CAN. Com base nos resultados obtidos, o **XGBoost** foi o modelo de melhor desempenho global, seguido de perto pelo **MLP**. Em seguida aparecem **Regressao Logistica** e **SVM**.

Em metricas globais, o XGBoost atingiu `accuracy = 0.99998` e `F1 macro = 0.99998`, enquanto o MLP obteve `accuracy = 0.99908` e `F1 macro = 0.99905`. Esses resultados sustentam a recomendacao principal desta pesquisa para o cenario experimental adotado.

6.2 Principais Achados

Os principais achados do trabalho sao:

- a comparacao com fonte canonica unica reduziu divergencias entre capitulos e aumentou a rastreabilidade dos resultados;
- classes **GEAR** e **RPM** apresentaram separacao quase perfeita na maior parte dos modelos;
- a classe **Fuzzy** foi a mais desafiadora, concentrando os menores valores de recall;
- modelos de maior capacidade representacional (MLP e XGBoost) superaram abordagens lineares no cenario avaliado.

6.3 Limitacoes

Apesar dos resultados elevados, este estudo possui limitacoes importantes:

- diferencas de tamanho entre os conjuntos de treino/teste por modelo;

- avaliacao restrita ao recorte final de cinco classes;
- ausencia de validacao em hardware embarcado e ambiente veicular em tempo real.

Esses pontos devem ser considerados na interpretacao de generalizacao dos resultados.

6.4 Trabalhos Futuros

Como continuidade desta pesquisa, recomendam-se as seguintes direcoes:

- validacao cruzada entre datasets e cenarios de coleta distintos;
- teste com ataques nao vistos para avaliar robustez fora da distribuicao de treino;
- avaliacao de latencia e throughput em plataforma alvo de implantacao;
- estudo de interpretabilidade para explicar decisoes em classes mais ambiguas, especialmente Fuzzy.

Em sintese, o trabalho cumpre seu objetivo ao estabelecer uma comparacao objetiva e reproduzivel entre modelos para IDS em rede CAN, oferecendo base tecnica consistente para evolucoes futuras em seguranca veicular.

Referências

Apêndices

APÊNDICE A – Repositório no GitHub

O código-fonte referente ao projeto "CICIDS2017: Detecção de Anomalias em Redes IoT com Técnicas de Inteligência Artificial e Aprendizado de Máquinas" está disponível no seguinte repositório do GitHub:

[Código-fonte no GitHub](#)

Este repositório contém implementações e recursos utilizados para a detecção de anomalias em redes IoT, conforme descrito na monografia. Os usuários podem encontrar detalhes sobre a coleta de dados, pré-processamento, modelagem de inteligência artificial e técnicas de aprendizado de máquinas empregadas no projeto.

Para reproduzir os resultados, consulte as instruções fornecidas no repositório.